Diseño de VUI con IA: Flujos, Herramientas y



CC451 Interacción Humano Computadora

AGENDA

01.
Arquitecturas y RAG

02.
Diseño y herramientas

03.
Casos y mejores prácticas

04.
Ética y futuro





01 Arquitecturas y RAG

Arquitecturas híbridas para VUI

Combinación de Intents y LLMs

Las VUI modernas integran intents tradicionales con LLMs para balancear velocidad, costo y calidad. Consultas simples se manejan con un intent router rápido y económico, mientras que las complejas se procesan con LLMs, mejorando la experiencia del usuario sin sacrificar eficiencia.

Ventajas de la Arquitectura Híbrida

Esta arquitectura híbrida permite respuestas deterministas para operaciones críticas y conversaciones naturales para consultas abiertas. Reduce costos y latencia, mientras mejora la experiencia del usuario, ofreciendo una solución versátil y eficiente.

Ejemplo Práctico

Por ejemplo, en un sistema de pedido de pizza, consultas sencillas como 'cancelar orden' se procesan rápidamente con intents, mientras que consultas complejas como 'qué me recomiendas para una cena romántica' se manejan con LLMs para ofrecer respuestas personalizadas.



Retrieval Augmented Generation

Definición y Funcionamiento

RAG añade información externa al contexto del LLM en tiempo real. Convierte la pregunta en un vector, busca documentos relevantes en una base de datos vectorial, inserta fragmentos en el prompt y genera una respuesta basada en hechos, evitando alucinaciones y mejorando la precisión.



Importancia en VUI Empresariales

Es esencial para VUI empresariales porque permite actualizar el conocimiento sin reentrenar el modelo, citar fuentes para aumentar la confianza y precisión, y manejar consultas específicas de la empresa de manera efectiva.

Pipeline RAG paso a paso



Fragmentación y Embebiendo

El flujo RAG comienza con documentos que se fragmentan en chunks, se embeben y se almacenan en una base de datos vectorial. Esto permite una búsqueda eficiente de información relevante en tiempo real.

Consulta y Recuperación

Cuando el usuario pregunta, el sistema embebe la consulta, recupera los k fragmentos más similares de la base de datos, los ordena y añade al prompt junto con instrucciones claras para el LLM.

Generación de Respuesta

El LLM genera una respuesta fundamentada en la información recuperada, que luego se convierte en voz mediante TTS, proporcionando una respuesta natural y bien informada al usuario.

Ejemplo Práctico

Por ejemplo, si un usuario pregunta sobre la política de devoluciones, el sistema recupera fragmentos relevantes del manual de la empresa, los añade al prompt y el LLM genera una respuesta precisa y actualizada.



02

Diseño y herramientas

Principios de diseño conversacional

Personalidad Coherente

Una VUI debe tener una personalidad coherente y apropiada al dominio. Por ejemplo, un banco usa un tono formal y vocabulario técnico, mientras que un servicio de delivery es casual y entusiasta. Esto mejora la confianza del usuario.



Documentación de Guía de Voz

Definir y documentar una guía de voz garantiza uniformidad entre desarrolladores y actualizaciones futuras. Incluye nivel de humor, reacciones empáticas y estilo visual para mantener la consistencia en toda la experiencia del usuario.

Progressive disclosure inteligente

Evitar Saturación de Opciones

Evita saturar al usuario con demasiadas opciones. Presenta 2-3 elecciones principales y revela sub-menús según la respuesta del usuario. Esto reduce la carga cognitiva y mejora la experiencia.



Permitir Interrupciones

Permite que el usuario interrumpa el flujo en cualquier momento y ofrece una opción de escape tipo '¿qué más puedo hacer?'. Esto mejora la flexibilidad y la satisfacción del usuario.

Ejemplo Práctico

Por ejemplo, en lugar de listar diez categorías, pregunta '¿Quieres comida o bebida?' y luego profundiza. Esto acorta el diálogo y mejora la tasa de éxito.

Divulgacion Progresiva

Mantener el enfoque de atencion, reduciendo desorden, confusion y carga de trabajo cognitivo

Esta técnica mejora la usabilidad al presentar solo los datos mínimos requeridos para la tarea en cuestión



Formas de responder

Yo: Max, ¿qué puedes hacer por mí?
Max: Puedo programar alarmas para ti. También puedo establecer recordatorios. ¿Quieres escuchar algunas cosas más que puedo hacer?

Confirmaciones según riesgo



Ajuste de Confirmación

Ajusta el nivel de confirmación a riesgo y confianza del sistema. Bajo riesgo + alta confianza: confirmación implícita. Alto riesgo + baja confianza: repetición explícita y verbal. Esto reduce fricción sin sacrificar seguridad.

Prevención versus corrección



Diseño para Prevenir Errores

Diseña para evitar errores antes que corregirlos. Usa defaults inteligentes, validación en tiempo real y clarificación proactiva. En voz, corregir es costoso; prevenir ahorra turnos y frustración.

Ejemplo Práctico

Por ejemplo, ante 'quiero 50 pizzas' advierte límite de 10 y ofrece asesor. En voz, la corrección es costosa; prevenir ahorra turnos y frustración.

Aprovechar el contexto



Tres formas de contexto

Contexto fisico:
Donde esta? Que esta Haciendo?

Contexto Emocional:
- Cual es su estado mental en el contexto fisico?
- Existe algun problema que el asistente pueda resolver en ese momento?

Contexto conversacional

- De que estaba hablando?
-Seguimos hablando de lo mismo o la conversacion ya cambio?

Cooperar y responder

Queremos saber mas sobre el individuo con el que conversamos

Desarrollar un sentido de la confianza para construir una “Relacion” o el habito de conversar.



Formas de responder

1. Si la pregunta es vaga, solicite más detalles.

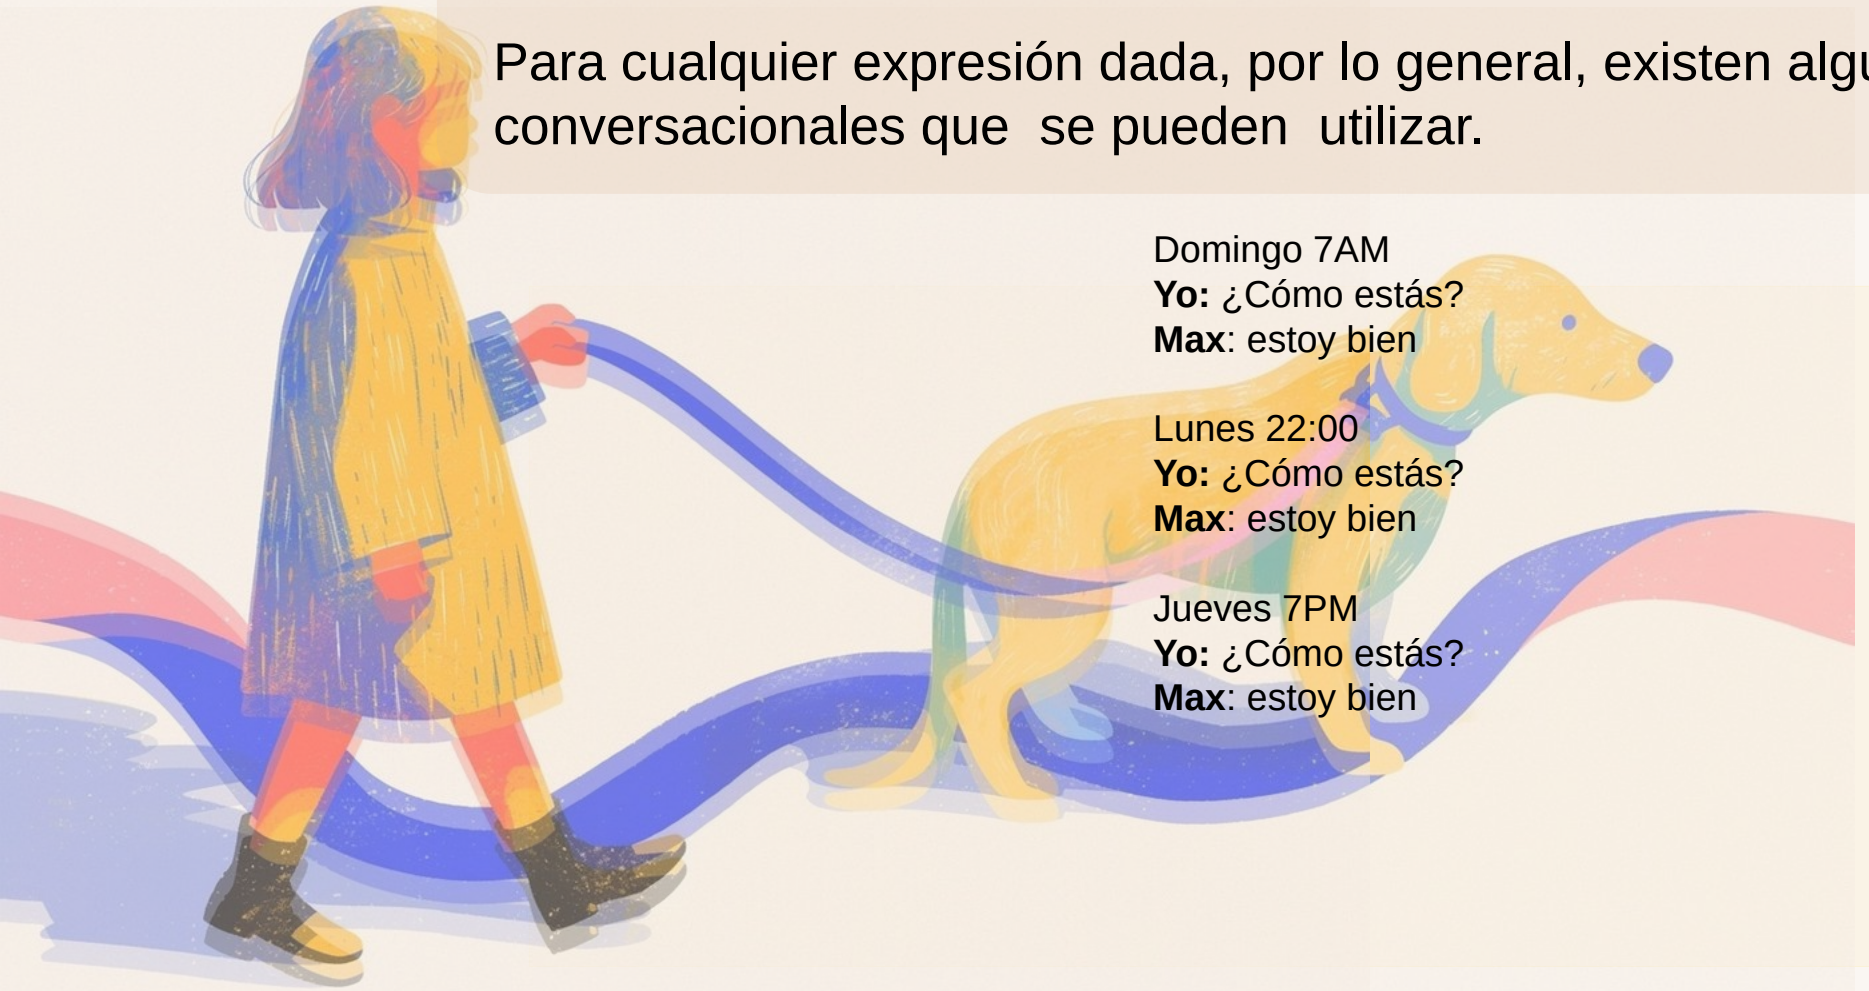
2. Si la respuesta es No, sugiera una alternativa o muestre una forma de satisfacer dicho propósito.

3. Dar más de lo esperado. Esto no quiere decir que el asistente suelta cada bit de información que tiene sobre el tema.

Variedad

Los humanos son quizás la única especie con el concepto de aburrimiento.

Para cualquier expresión dada, por lo general, existen algunas alternativas conversacionales que se pueden utilizar.



Domingo 7AM
Yo: ¿Cómo estás?
Max: estoy bien

Lunes 22:00
Yo: ¿Cómo estás?
Max: estoy bien

Jueves 7PM
Yo: ¿Cómo estás?
Max: estoy bien

Domingo 7AM
Yo: ¿Cómo estás?
Max: Estoy bien, tomando el sol ahora mismo en mi espacio digital.
.

Lunes 22:00
Yo: ¿Cómo estás?
Max: En este momento, estoy feliz porque disfrutaste tu viaje a Arequipa.

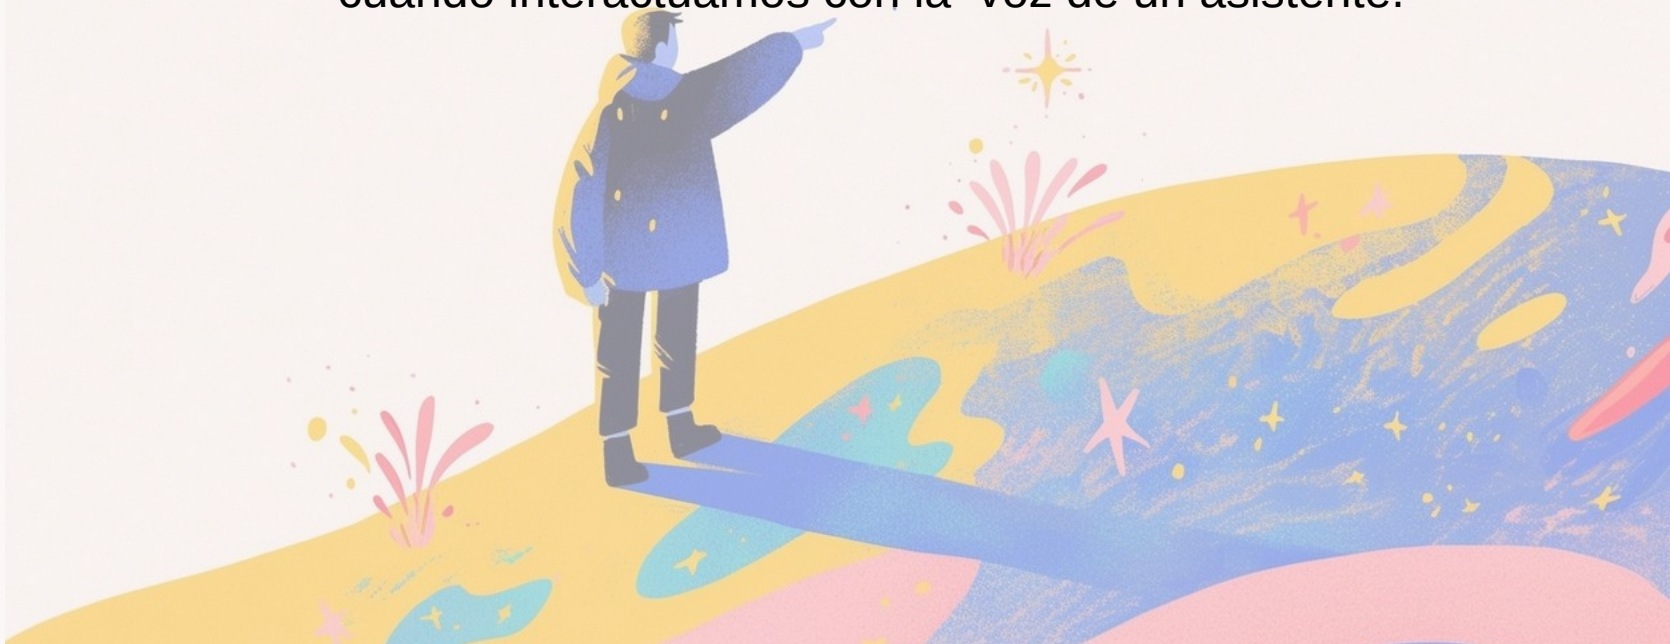
Personalidad

Una caracteristica que valoramos

Los *objetos* con los que los humanos más interactuamos en nuestras vidas son otras personas. Por esta razón ponemos más esfuerzo estudiando sus rostros; tratando de entender cómo se sienten, sus pensamientos, etc. Esta es una característica del instinto de supervivencia.

Los humanos realmente queremos entender el mundo que nos rodea. **Una forma de hacerlo es proyectar una personalidad al objeto con el que interactuamos y tratar de entenderlo o 'leerlo**'.

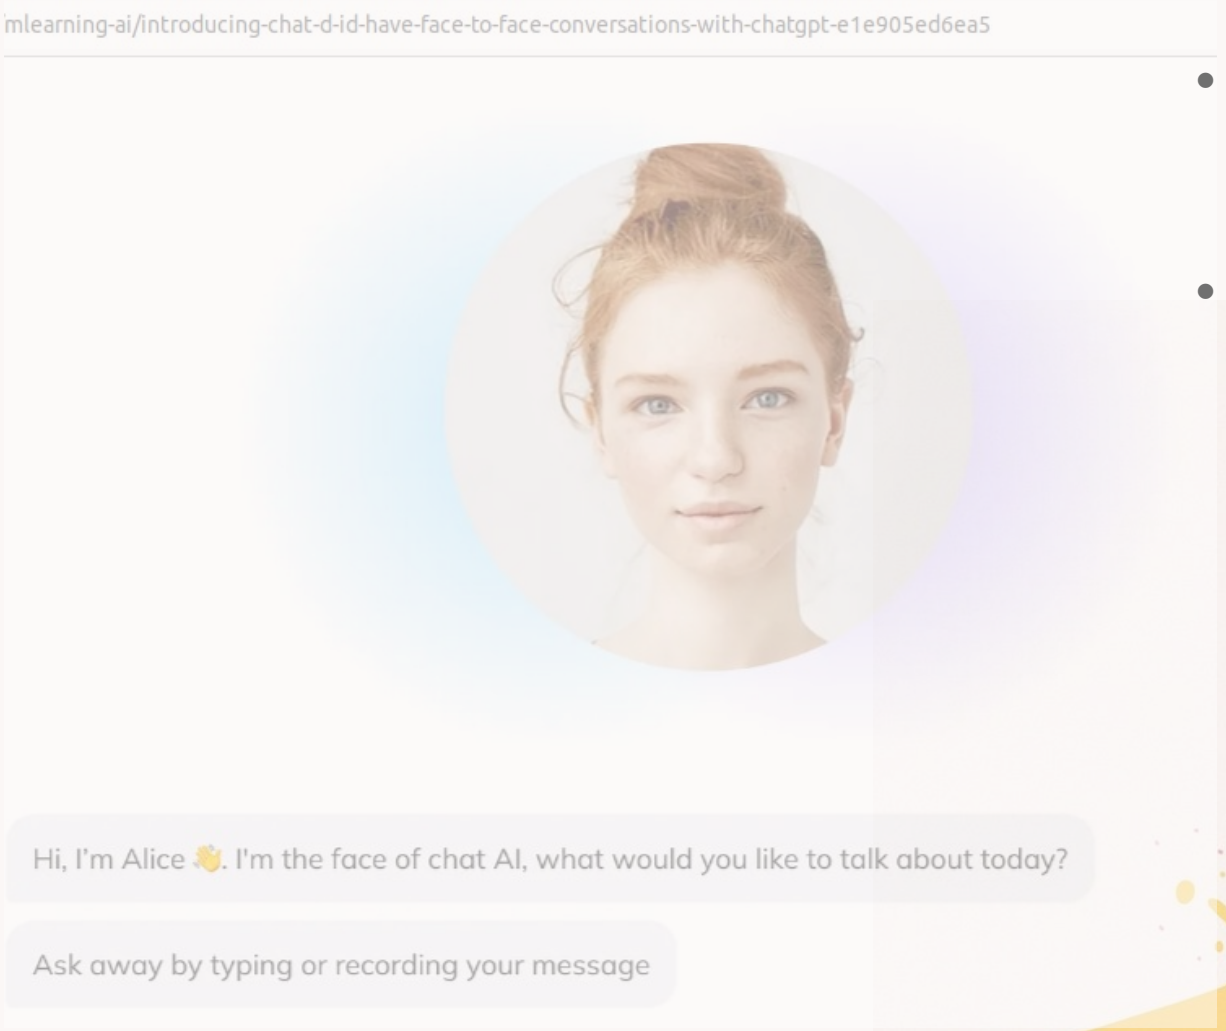
Esto también es aplicable a las voces incorpóreas:
Supongamos que usted llama a un extraño por teléfono.
Inmediatamente, **creará una persona para esa voz**. Comenzará con el género, luego hará suposiciones sobre edad, altura, peso, etc. Lo mismo sucede cuando interactuamos con la voz de un asistente.



Personalidad

Una caracteristica que valoramos

Los humanos realmente queremos entender el mundo que nos rodea. **Una forma de hacerlo es proyectar una personalidad al objeto con el que interactuamos y tratar de entenderlo o 'leerlo'**.



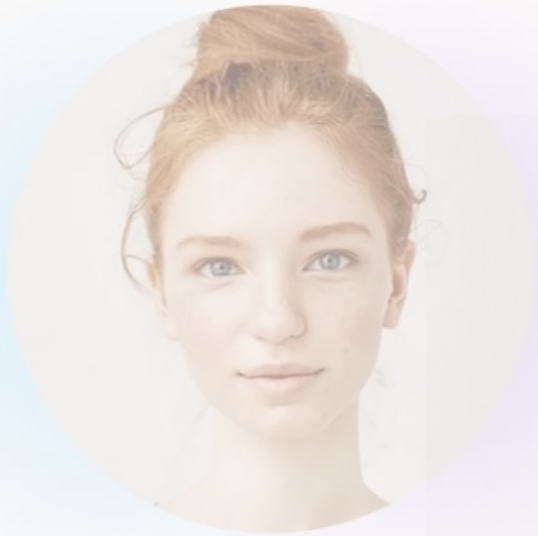
- Definir la personalidad: Se puede utilizar El modelo Big 5 – de rasgos de personalidad - OCEAN
- mide aspectos como la apertura, la escrupulosidad, la extroversión, la amabilidad y el neuroticismo.



Personalidad

Una caracteristica que valoramos

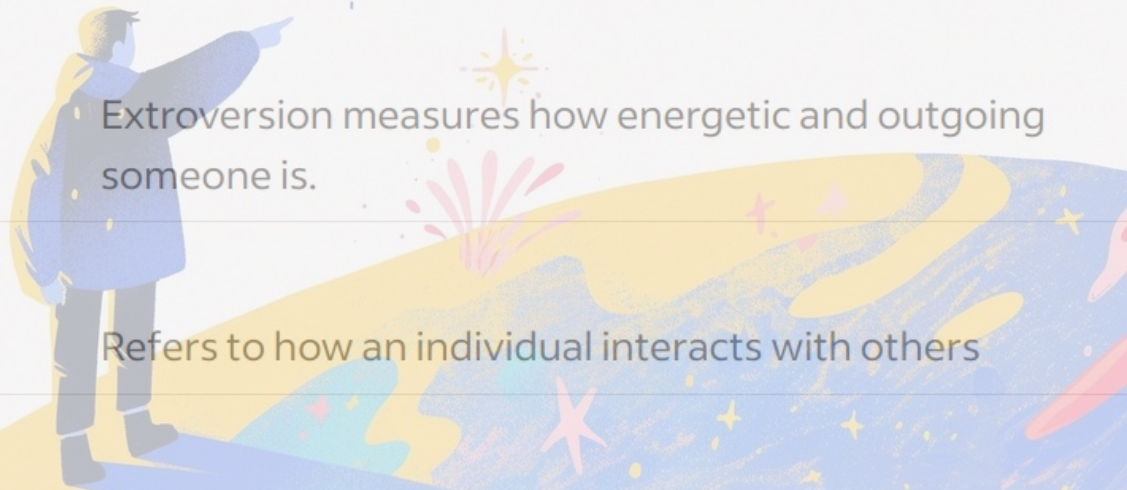
mlearning-ai/introducing-chat-d-id-have-face-to-face-conversations-with-chatgpt-e1e905ed6ea5



Hi, I'm Alice 👋. I'm the face of chat AI, what would you like to talk about today?

Ask away by typing or recording your message

Openness	Openness represents how willing a person is to try new things.
Conscientiousness	Conscientiousness refers to an individual's desire to be careful and diligent.
Extroversion	Extroversion measures how energetic and outgoing someone is.
Agreeableness	Refers to how an individual interacts with others
Neuroticism	Represents how likely someone is to experience negative emotions



Personalidad

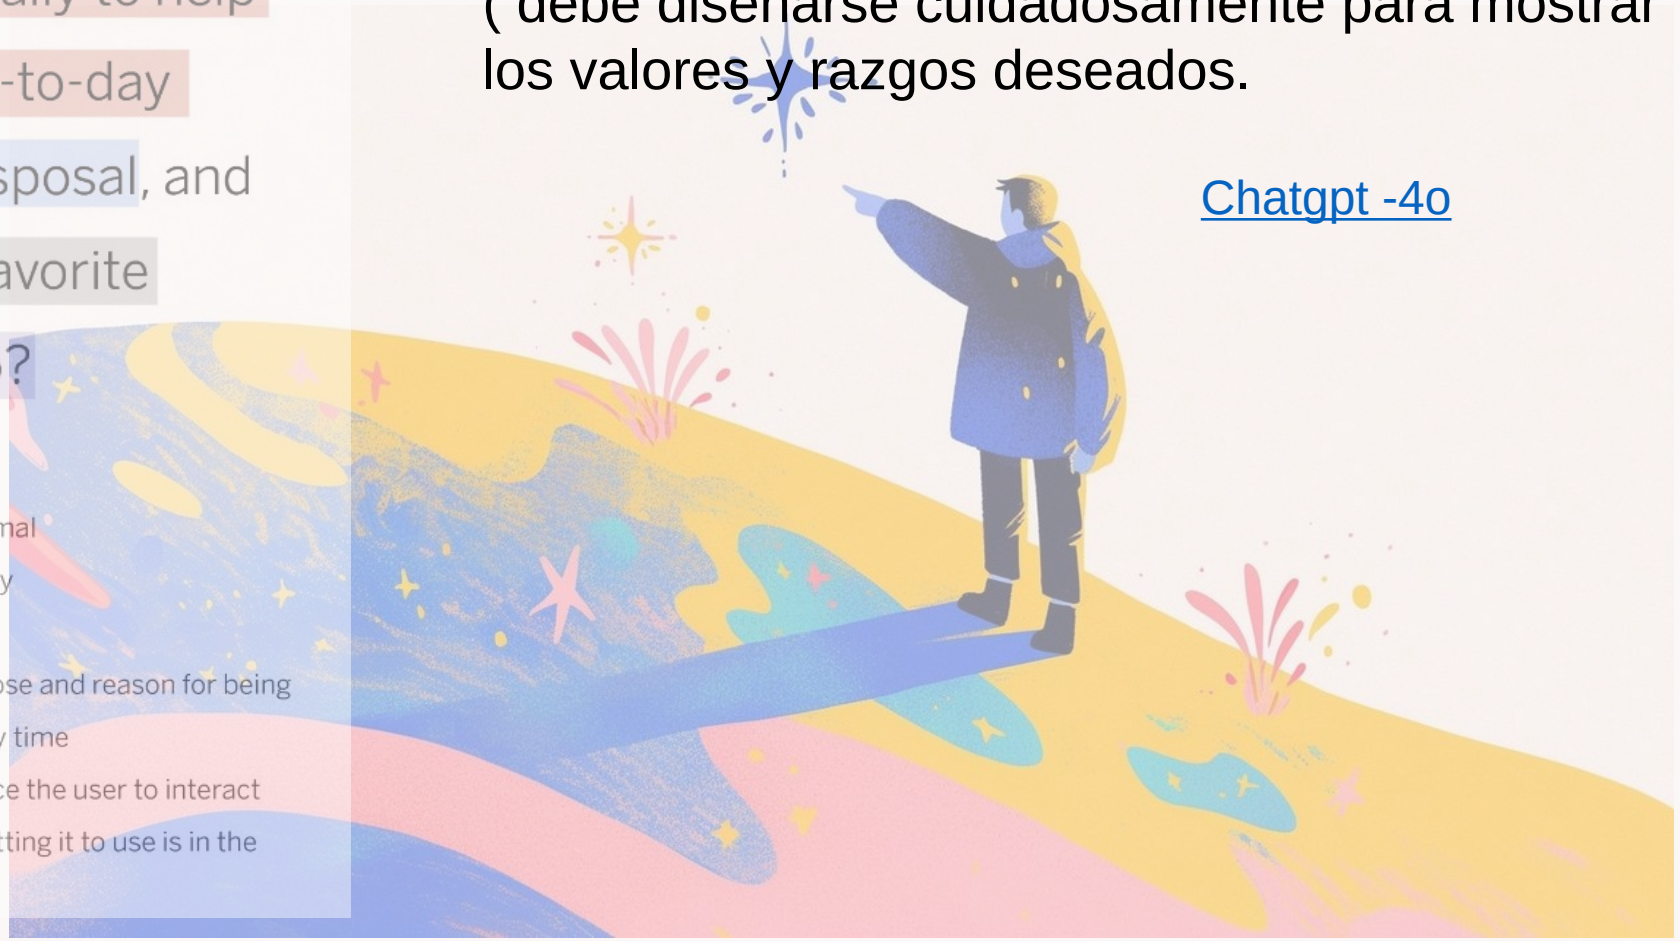
Una caracteristica que valoramos

Hi Maria. Finally we meet! My name is Blue, and BBVA designed me specifically to help you better understand your day-to-day finances. I am always at your disposal, and running numbers is one of my favorite tasks. What would you like to do?

Enthusiastic:	A cheerful greeting that doesn't sound too formal
Chummy:	Using first names to denote a sense of intimacy
Supportive:	Encourages the user to interact
Sincere:	Open and communicative, describing its purpose and reason for being
Willing:	Encourages the customer to use its help at any time
Persuasive:	Introducing itself as a reliable guide, to convince the user to interact
Practical:	Blue was created to be useful and efficient. Putting it to use is in the best interest of the user's finances

Reflejar la personalidad a lo largo de la conversación:

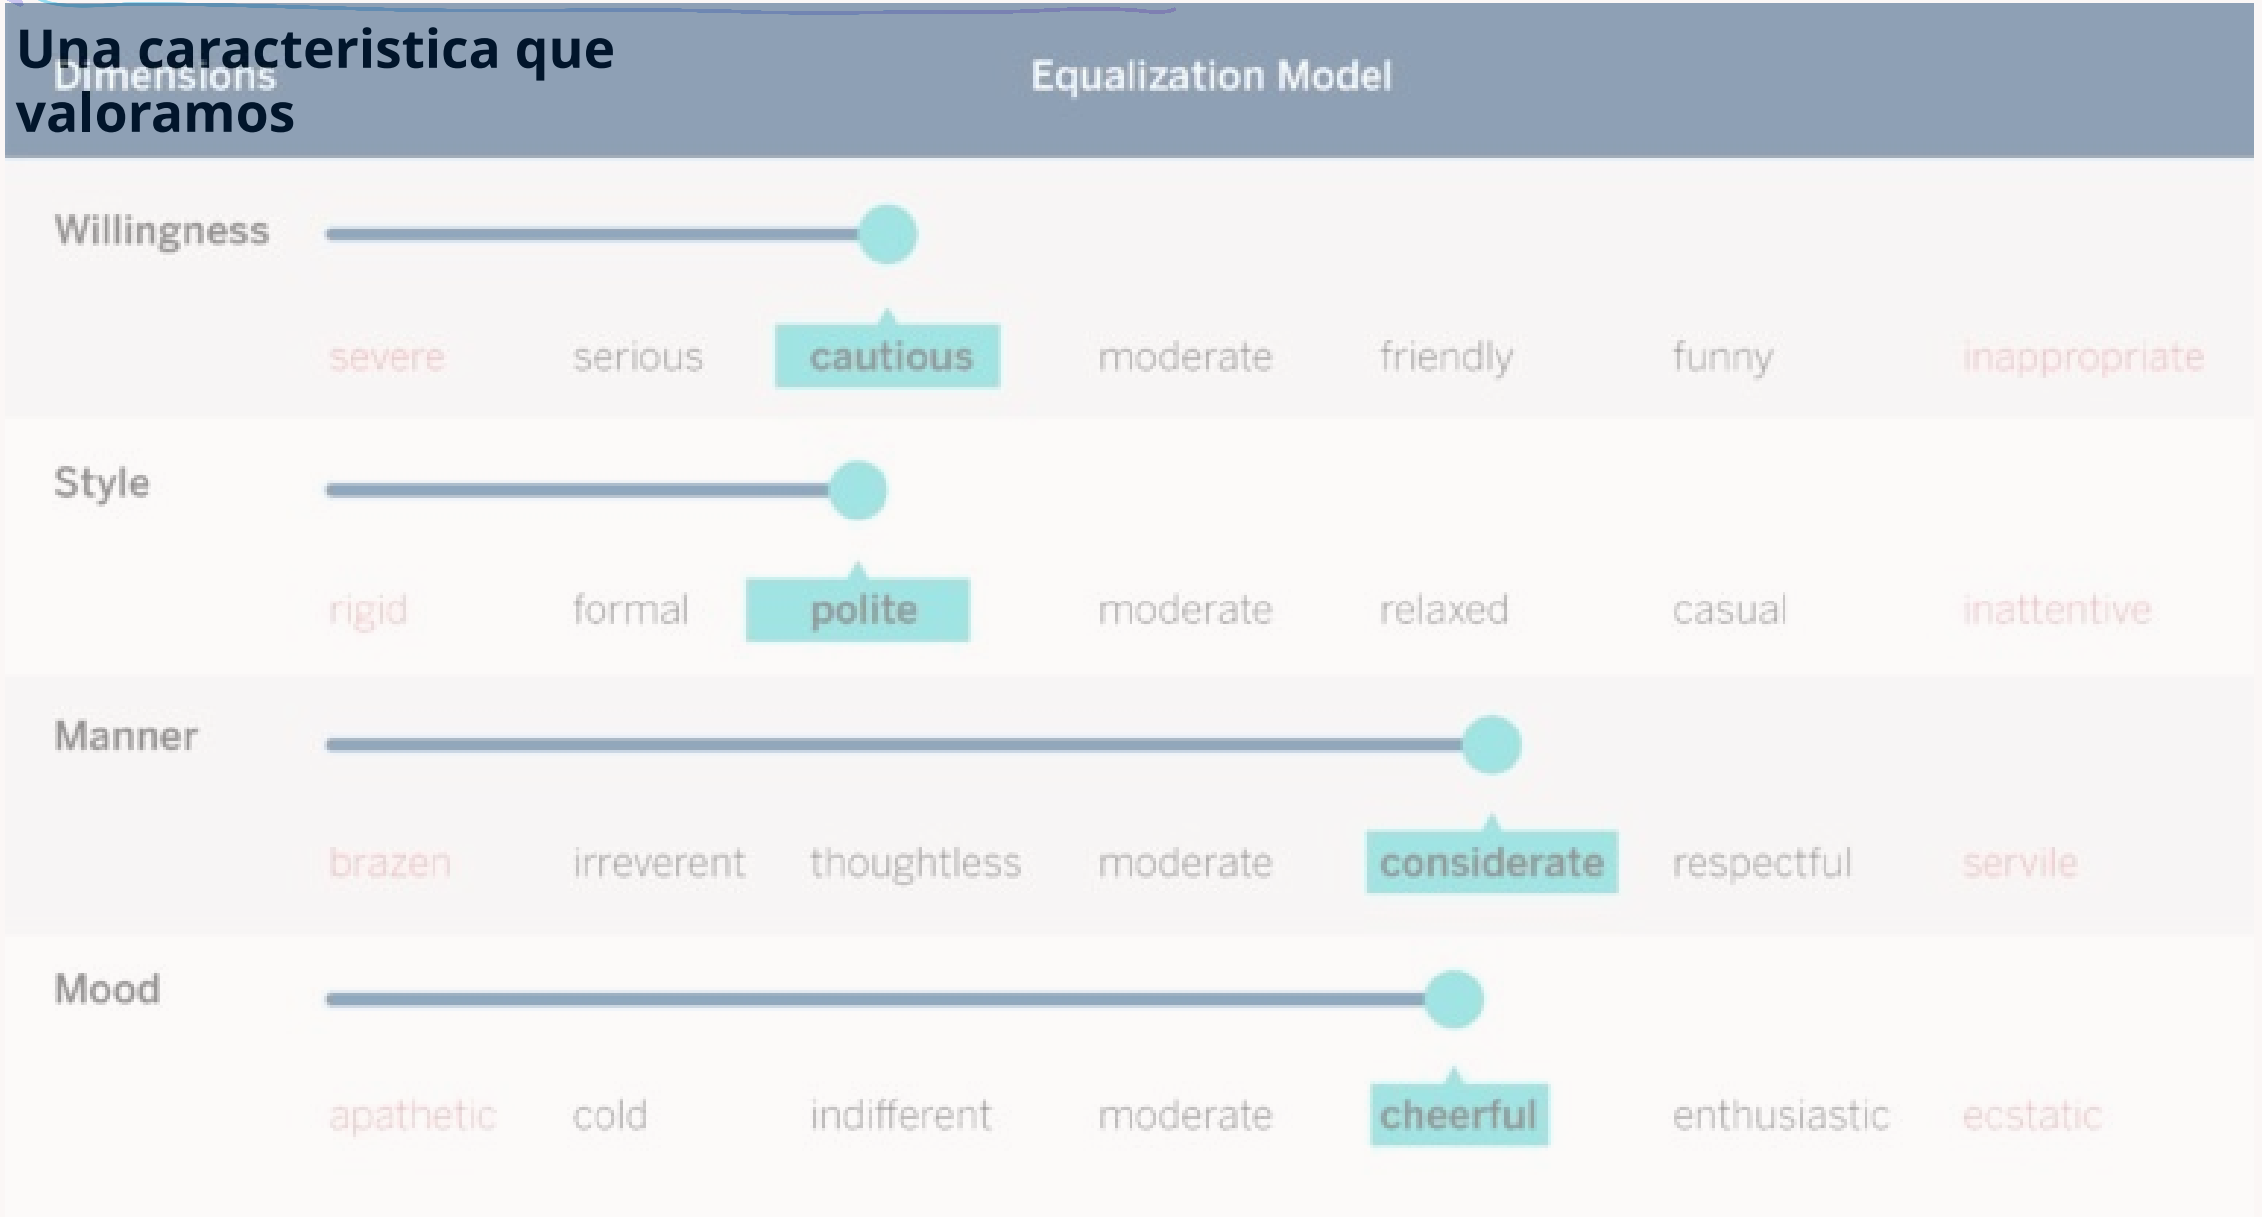
hay escenarios en los que La personalidad resalta con más fuerza. Por ejemplo, el saludo (debe diseñarse cuidadosamente para mostrar los valores y razgos deseados.



Chatgpt -4o

Personalidad y el tono de voz

Una caracteristica que valoramos



Voiceflow y plataformas 2025

Voiceflow: Diseño Visual

Voiceflow lidera el diseño visual con integración LLM: arrastrar bloques Speak, Capture, If, API y AI; conectar con GPT-4 o Claude sin código; subir documentos para RAG; probar flujos en canvas.



Alternativas en el Mercado

Alternativas: Botpress open-source, Dialogflow CX empresarial, Amazon Lex V2 con Alexa. Eligen según control, presupuesto y canal de despliegue.

Ejemplo Práctico

Por ejemplo, Voiceflow permite crear un flujo simple en vivo, integrar LLMs y probar interacciones en tiempo real, facilitando el desarrollo y la iteración rápida.



03

Casos y mejores prácticas

Case study: Pizza Express

Implementación Exitosa

Ejemplo real: VUI reduce tiempo de orden de 4 minutos a 90 segundos. Arquitectura: Whisper → Intent Router → Dialog Manager para órdenes simples; consultas abiertas van a GPT-4 con RAG sobre menú.



Resultados y Claves

Resultados: 95 % comprensión, 78 % tasa éxito sin intervención humana, ahorro 30 % costo operativo. Claves: entrenar RAG con FAQs reales, logs continuos para ajustar router, TTS con voz local para conexión cultural.

Manejo de quejas con empatía

Detección de Frustración

Al detectar frustración, la VUI cambia tono: habla más lento, usa palabras empáticas y ofrece soluciones concretas. Ejemplo: 'Lamento que tu pizza haya llegado fría. Te envío una nueva sin cargo o reembolso completo. Tu ticket es C789.'

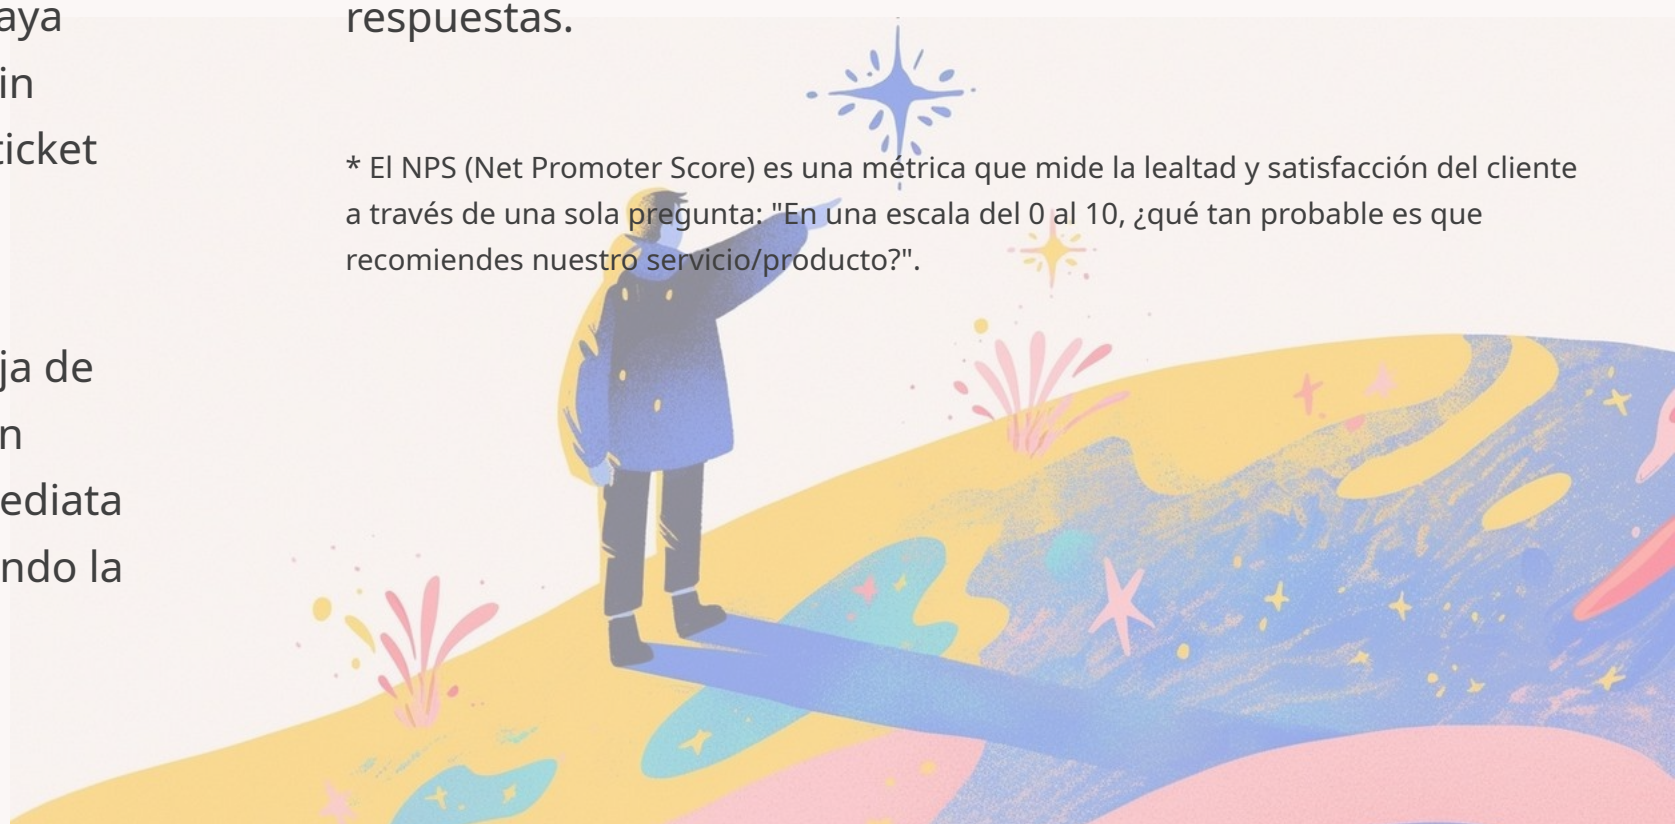
Ejemplo Práctico

Por ejemplo, si un usuario se queja de una pizza fría, la VUI responde con empatía, ofrece una solución inmediata y un cupón de descuento, mejorando la satisfacción del cliente.

Evitar Excusas Corporativas

Evita excusas corporativas genéricas; enfócate en la reparación. Añade cupón descuento y opción humana si persisten insultos. Mide NPS* post-interacción para ajustar respuestas.

* El NPS (Net Promoter Score) es una métrica que mide la lealtad y satisfacción del cliente a través de una sola pregunta: "En una escala del 0 al 10, ¿qué tan probable es que recomiendes nuestro servicio/producto?".



Testing conversacional real



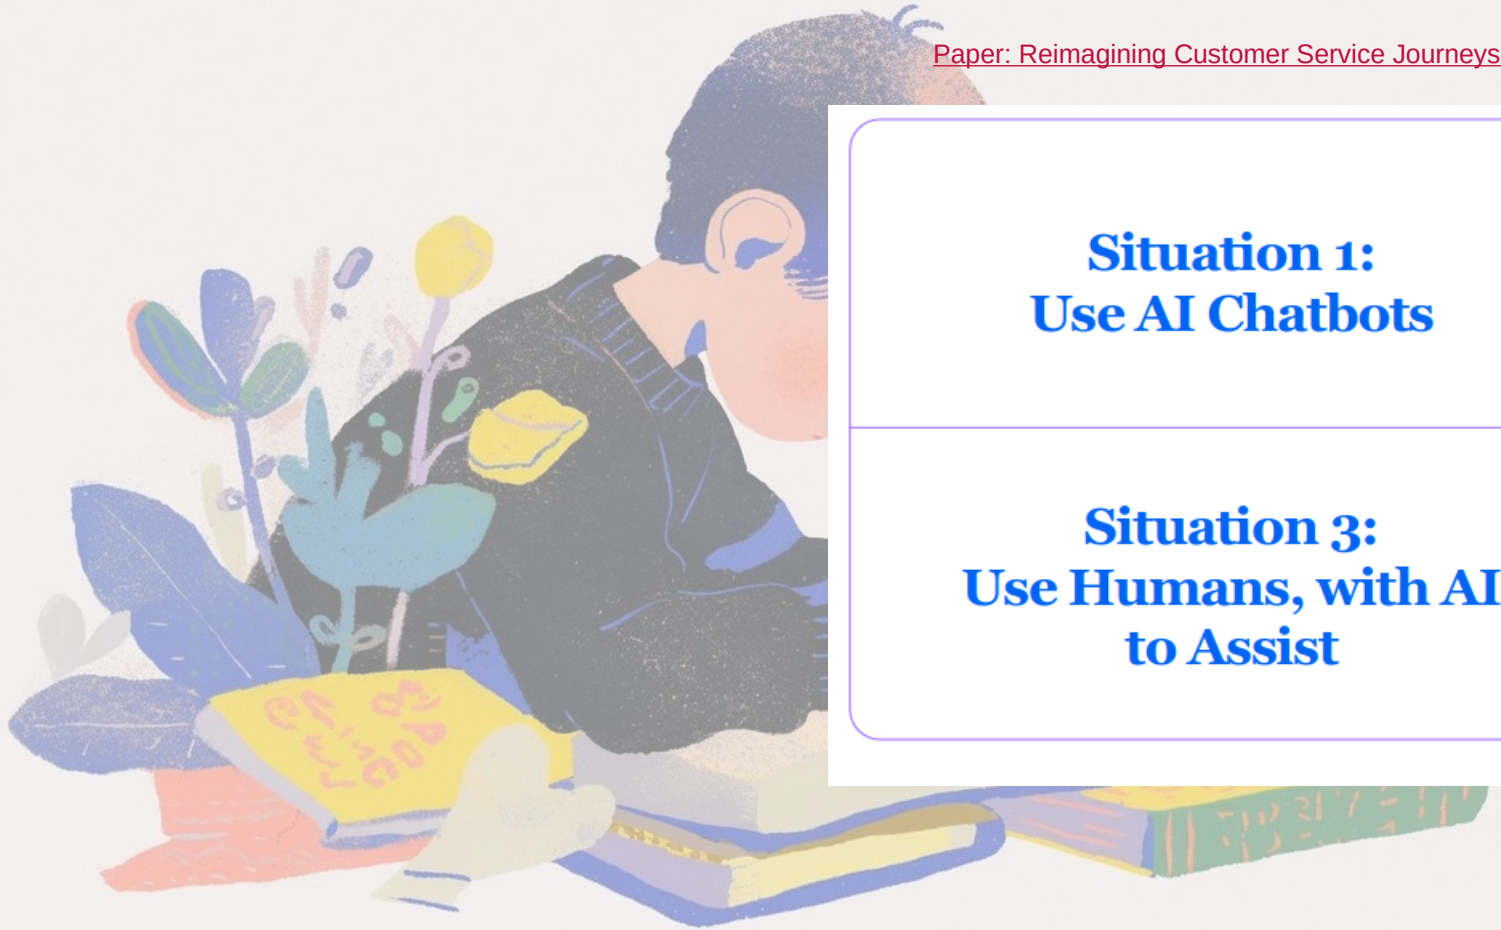
Evaluación con Usuarios Reales

Evalúa con usuarios reales en entorno ruidoso. Define métricas: tasa éxito tarea, tiempo promedio, turnos por diálogo, satisfacción post-llamada. Usa un test A/B para probar frases de confirmación. Recoge logs de fallos: categoriza por tipo (ASR, NLU, lógica) y prioriza.

Como usar AI, chatbots, y humanos en la practica?

Famework de Wharton U
.

Antes de pensar en cómo optimizar tu chatbot de IA, ¿estás seguro de que deberías usar uno?



Paper: Reimagining Customer Service Journeys with LLMs: A Framework for Chatbot Design and Workflow Integration

Situation 1: **Use AI Chatbots**	**Situation 2:** **Use AI Chatbots, with Light Human Supervision**
Situation 3: **Use Humans, with AI to Assist**	**Situation 4:** **Use Humans**

Como usar AI, chatbots, y humanos en la practica?

Famework de Wharton U
.



Situacion 1: - Usar Chat Bots

Cuándo usarla: En industrias de alto volumen, orientadas a tareas repetitivas y de bajo riesgo, como viajes, comercio minorista, logística y hostelería.

Ejemplos:
La IA gestiona consultas de facturación, seguimiento de equipaje y actualizaciones de vuelos sin intervención humana.

La IA gestiona actualizaciones del estado de reembolsos y el seguimiento de pedidos **para miles de clientes.**

Cómo funciona:
La IA opera de forma independiente, con auditorías humanas ocasionales para garantizar la precisión y el rendimiento.

Como usar AI, chatbots, y humanos en la practica?

Famework de Wharton U



Situacion 2: - Usar Chat Bots de IA, con una ligera supervicion humana

Cuándo usarla:
Procesamiento de historiales médicos, informes financieros,
comercio electrónico, banca en línea, atención al cliente gubernamental o reducción de la carga de trabajo humana en tareas repetitivas manteniendo la calidad mediante la supervisión.

Ejemplos:
La IA interpreta las imágenes y prepara los informes de diagnóstico iniciales. Los radiólogos los aprueban o modifican antes de finalizarlos. La IA gestiona el chat en vivo para el seguimiento de pedidos y consultas sobre productos. Los humanos intervienen en los casos complejos. La IA se encarga de las consultas y los problemas más comunes, derivando los problemas no resueltos al personal de TI.

Cómo funciona:
La IA redacta respuestas o gestiona las interacciones. Los humanos revisan el contenido antes de enviarlo o supervisan las interacciones en tiempo real e intervienen cuando es necesario.

Como usar AI, chatbots, y humanos en la practica?

Famework de Wharton U
.



Situacion 3: - Usar Humanos, teniendo la IA como asistente

Cuándo usarla:
Consultas médicas, asesoría financiera, centros de atención telefónica complejos, reclamaciones de seguros, revisión de documentos legales y resolución de disputas con clientes.

Ejemplos:
Durante las llamadas con los pacientes, si una enfermera proporciona información incorrecta sobre el copago u omite instrucciones postoperatorias cruciales, la IA lo detecta inmediatamente para su corrección. La IA supervisa a los asesores financieros para garantizar el cumplimiento de las políticas de inversión durante las llamadas con los clientes. La IA sugiere acuerdos de indemnización, pero los peritos toman la decisión final.

Cómo funciona:
La IA monitoriza las conversaciones humanas en tiempo real para detectar errores y ofrece apoyo en la toma de decisiones sugiriendo opciones. Los humanos mantienen el control final sobre las decisiones y las respuestas.

Como usar AI, chatbots, y humanos en la practica?

Famework de Wharton U
.



Situacion 4: - Usar Humanos.

Cuándo usarla:
Industria legal, industria con estrictas regulaciones y empresas donde la precisión es fundamental.

Ejemplos:
Un centro de llamadas donde las enfermeras responden preguntas preoperatorias, como "¿Cuándo es mi última comida antes de la cirugía?". La IA puede revisar las transcripciones a posteriori para garantizar un asesoramiento médico coherente. Bufetes de abogados que gestionan las consultas de los clientes directamente con los abogados. La IA puede auditar las conversaciones para mejorar la calidad, pero no interfiere en tiempo real.

Cómo funciona:
Las personas gestionan todas las interacciones. Aun así, conviene usar la IA para revisar las conversaciones posteriormente e identificar errores y tendencias..



04 Ética y futuro

Ethical design checklist



1. Transparencia y Consentimiento

Verifica si: ¿usuario sabe que habla con IA? ¿Puede borrar grabaciones? ¿Hay un indicador visual cuando micrófono activo? ¿Se evita la recolección de datos sensibles sin consentimiento? Se Implementa el consentimiento granular y la data retention mínima.

2. Auditoría de Sesgos

Se Audita sesgo de ASR por género o acento?. Documenta en la política de privacidad de forma clara y accesible. El objetivo es permitir decisiones informadas y el control total del usuario sobre sus datos.

Ética y privacidad en VUI



3. Riesgos de la Voz Biométrica

La voz es biométrica: puede identificar emociones, estado de salud, origen.
Riesgos: voiceprint sin consentimiento, micrófonos siempre activos, filtración conversaciones ambientales.

4. Mitigación de Riesgos

Mitiga: cifrar audio en tránsito y reposo, indicador visual de grabación, permitir opt-out de almacenamiento, anonimizar logs, auditar sesgos ASR por género o acento, cumplir GDPR/CCPA,

y la Ley 29733: que exige la protección de datos personales en Perú

Tendencias 2025-2027

VUI Ambientales Proactivas

VUI ambientales proactivas detectan contexto y ofrecen ayuda sin comando. Por ejemplo, detecta que te estás vistiendo y sugiere la temperatura afuera.



Emotional Intelligence

VUI con emotional intelligence detecta frustración, urgencia o satisfacción en el tono de voz y adapta respuestas en tiempo real para mejorar la interacción.

Continuous Conversations

No más 'wake words'. VUI entiende contexto de ambiente, sabe cuándo el usuario le habla vs. habla con otros, manteniendo conversaciones fluidas y naturales.

Desafíos pendientes

Problemas y desafios

Problema cocktail party: separar múltiples voces y ruido.
Long-form understanding: recordar detalles tras 30 min.
Cultural nuance: humor e ironía locales.
Trust: verificar veracidad sin degradar UX.
Regulation: leyes lentas vs. tecnología rápida.



Próximos pasos

Resumen

Resumen: evolución desde comandos a IA conversacional, fundamentos técnicos modernos, principios diseño empático, arquitecturas híbridas y RAG, consideraciones éticas y producción.



Recursos y Oportunidades

Recursos:

Effective AI Chatbots