Interfaces de Voz y IA

Diseño Moderno de VUI en la Era de la IA Generativa

CC451 - Interacción Humano Computadora

Sesión 1: Fundamentos y Tecnología

Agenda de la Clase

01 **Evolución de las VUI**
De comandos a conversaciones naturales

02 **Fundamentos Técnicos**
ASR, NLU y síntesis de voz

03 **IA Generativa y LLMs**
ChatGPT, Claude, Gemini

04 **Arquitectura Moderna**
Sistemas híbridos y pipelines

05 **Principios de Diseño**
Más allá de los comandos

06 **Herramientas 2024-2025**
Voiceflow y alternativas

07 **Casos de Estudio**
Proyecto práctico

Duración: 2 sesiones de 90 minutos • Enfoque práctico para ingenieros

Sesión 1

Fundamentos y Tecnología

Evolución técnica desde comandos simples hasta conversaciones inteligentes impulsadas por IA

Evolución de las VUI: Tres Generaciones

Primera Generación

2011-2019

Basadas en Intents y Slots (Entities) con comandos estructurados. Siri inicial, Alexa Skills básicas. Limitaciones en flexibilidad y manejo de variaciones lingüísticas.

Segunda Generación

2020-2023

NLU Avanzado con BERT y Transformers. Mejor comprensión contextual y personalización limitada. Alexa Skill Flows, Google Assistant Continued Conversation.

Tercera Generación

2023-2026

LLMs e IA Generativas para conversaciones verdaderamente naturales. Comprensión profunda del contexto y capacidad de razonamiento. ChatGPT Voice, Claude, Gemini Live.

No estamos reemplazando VUI tradicionales, sino expandiendo capacidades. Los sistemas modernos combinan ambos enfoques.

MODERN VOICE AI · PIPELINE

Pipeline de un VUI Moderno

De la voz del usuario a la respuesta natural en 8 etapas

⚡ OBJETIVO: < 700 ms



⚡ El secreto del diseño moderno: Streaming + Asincronía

- 🔹 **ASR en streaming** — texto parcial mientras habla
- 🔹 **Objetivo: < 700 ms** — al primer audio percibido
- 🔹 **TTS en streaming** — audio parcial mientras genera
- 🔹 **Barge-in natural** — interrumpe al asistente hablando
- 🔹 **Pipeline productor-consumidor** — etapas asíncronas sin bloqueo
- 🔹 **Wake Word local** — privacidad y bajo consumo

Pipeline Completo de VUI Moderno

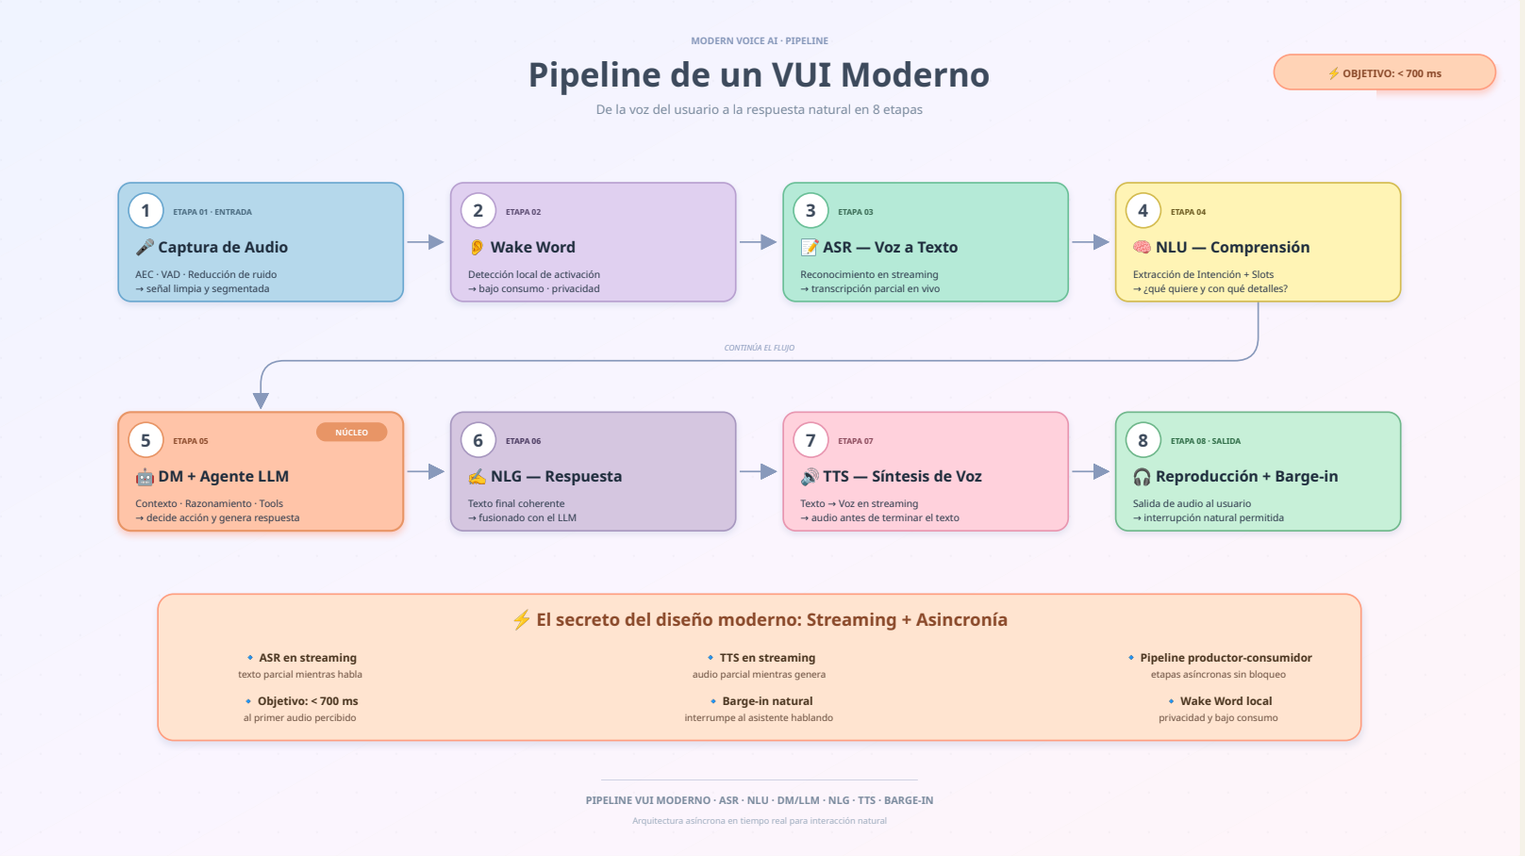
1. Captura y Preprocesamiento de Audio

Es la puerta de entrada. El dispositivo captura la voz del usuario y aplica técnicas para mejorar la calidad de la señal antes de procesarla. Esto incluye:

Cancelación de Eco Acustico (AEC): Para que el micrófono no se sature con la propia voz del asistente.

Detección de Actividad de Voz (VAD): Identifica cuándo el usuario está hablando y cuándo hay silencio para segmentar el audio correctamente.

Reducción de Ruido: Filtra sonidos de fondo para aislar la voz humana



Pipeline Completo de VUI Moderno

2. Detección de Palabra de Activación (Wake Word)

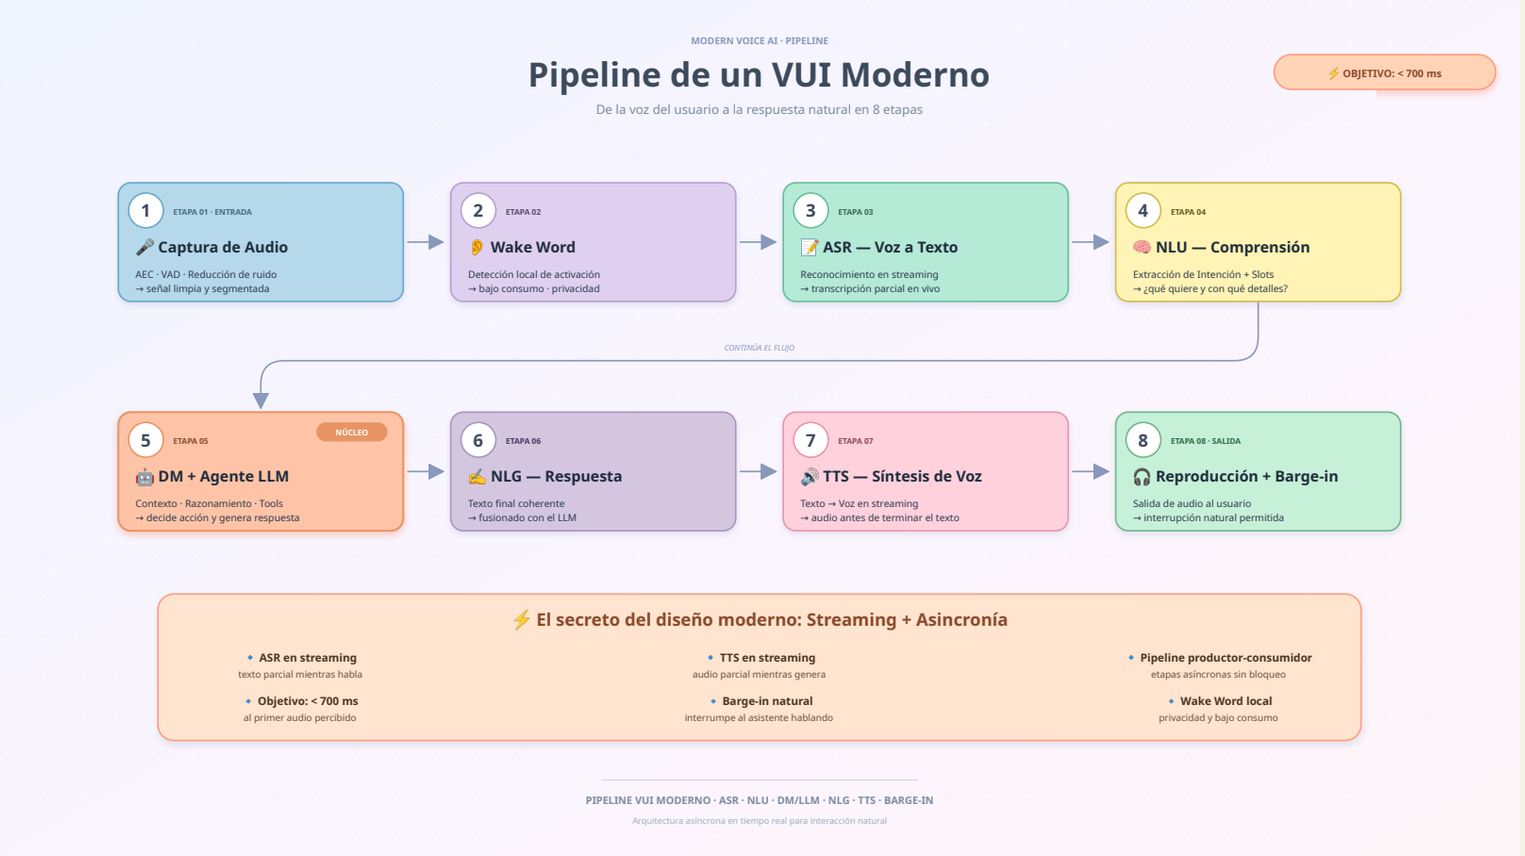
Para evitar que el sistema esté siempre escuchando, se utiliza un detector de palabra de activación. El dispositivo permanece en un estado de bajo consumo hasta que "oye" una frase específica (ej. "Oye, asistente", "Okay Nabu"). En muchos dispositivos modernos, esta detección se realiza localmente (en el propio hardware) para mayor privacidad y velocidad.



Pipeline Completo de VUI Moderno

3. Reconocimiento Automático del Habla (ASR)

Una vez activado, el audio se convierte en texto. Los sistemas modernos utilizan ASR en streaming, que genera transcripciones parciales mientras el usuario aún está hablando, en lugar de esperar a que termine la frase por completo. Esto es crucial para reducir la latencia percibida.



Pipeline Completo de VUI Moderno

4. Comprensión del Lenguaje Natural (NLU)

El texto transcrito pasa a la etapa de NLU, cuyo objetivo es extraer el significado de la utterance. Aquí se identifican dos elementos clave:

Intención (Intent): ¿Qué quiere hacer el usuario? (ej. reproducir_musica, consultar_clima).

Entidades (Slots): Los detalles específicos de la petición (ej. el nombre de la canción, la ciudad).



Pipeline Completo de VUI Moderno

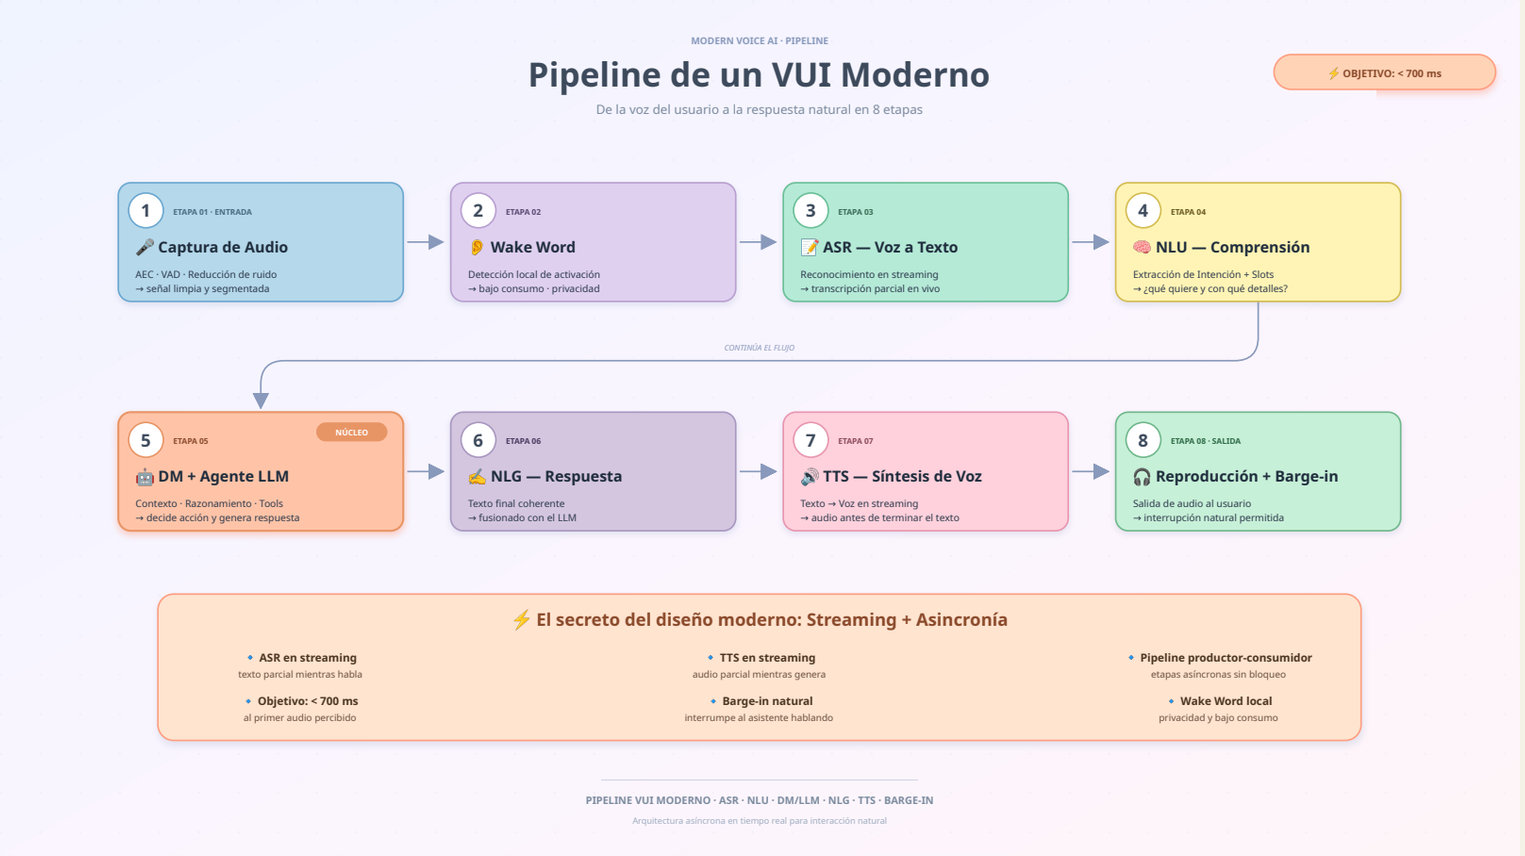
5. Gestión del Diálogo (DM) y Agente LLM

Esta es la "capa de pensamiento". El Gestor de Diálogo (DM) mantiene el contexto de la conversación (los turnos anteriores) y decide cuál es el siguiente paso. En los VUI modernos, esta capa a menudo se implementa con un Agente basado en un Modelo de Lenguaje Grande (LLM). El LLM no solo entiende la intención, sino que también puede:

Razonar sobre la petición.

Decidir si necesita invocar una herramienta externa (API del clima, reproductor de música, etc.).

Generar la respuesta en lenguaje natural.



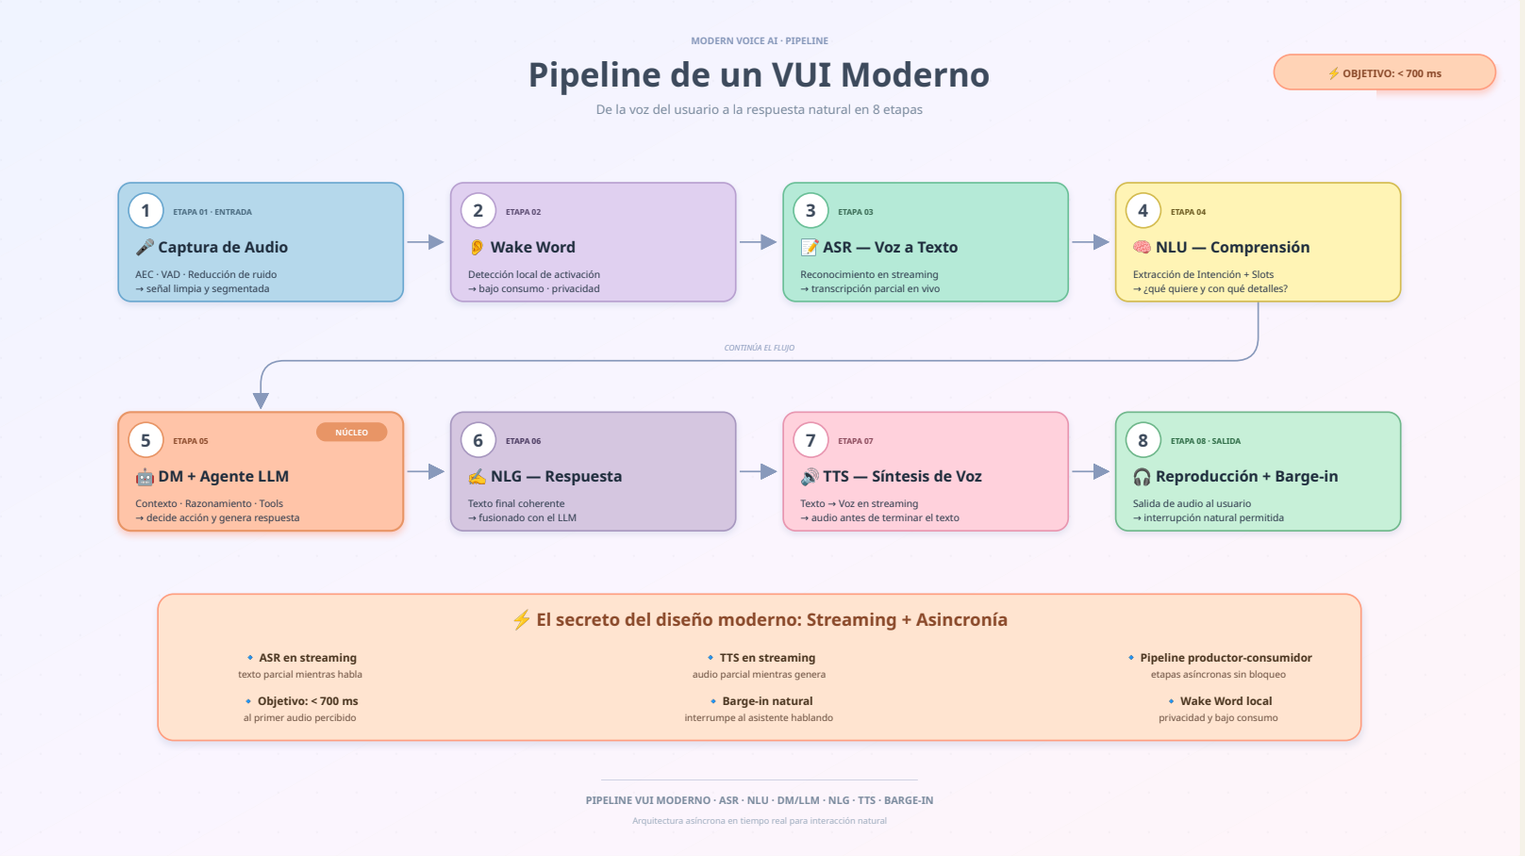
Pipeline Completo de VUI Moderno

6. Generación de Lenguaje Natural (NLG) / Formulación de la Respuesta

El resultado del paso anterior (una acción o un texto generado por el LLM) se convierte en una respuesta textual final. En arquitecturas modernas con LLM, la NLG y la DM están fusionadas, ya que el propio modelo genera directamente el texto de respuesta de forma coherente y contextual.

7. Síntesis de Voz (TTS)

El texto de respuesta se convierte de nuevo en audio. Al igual que el ASR, el TTS (Text-to-Speech) moderno es en streaming. Comienza a generar el audio antes de que el LLM haya terminado de escribir toda la respuesta, lo que permite que el usuario empiece a escuchar la contestación casi al instante.



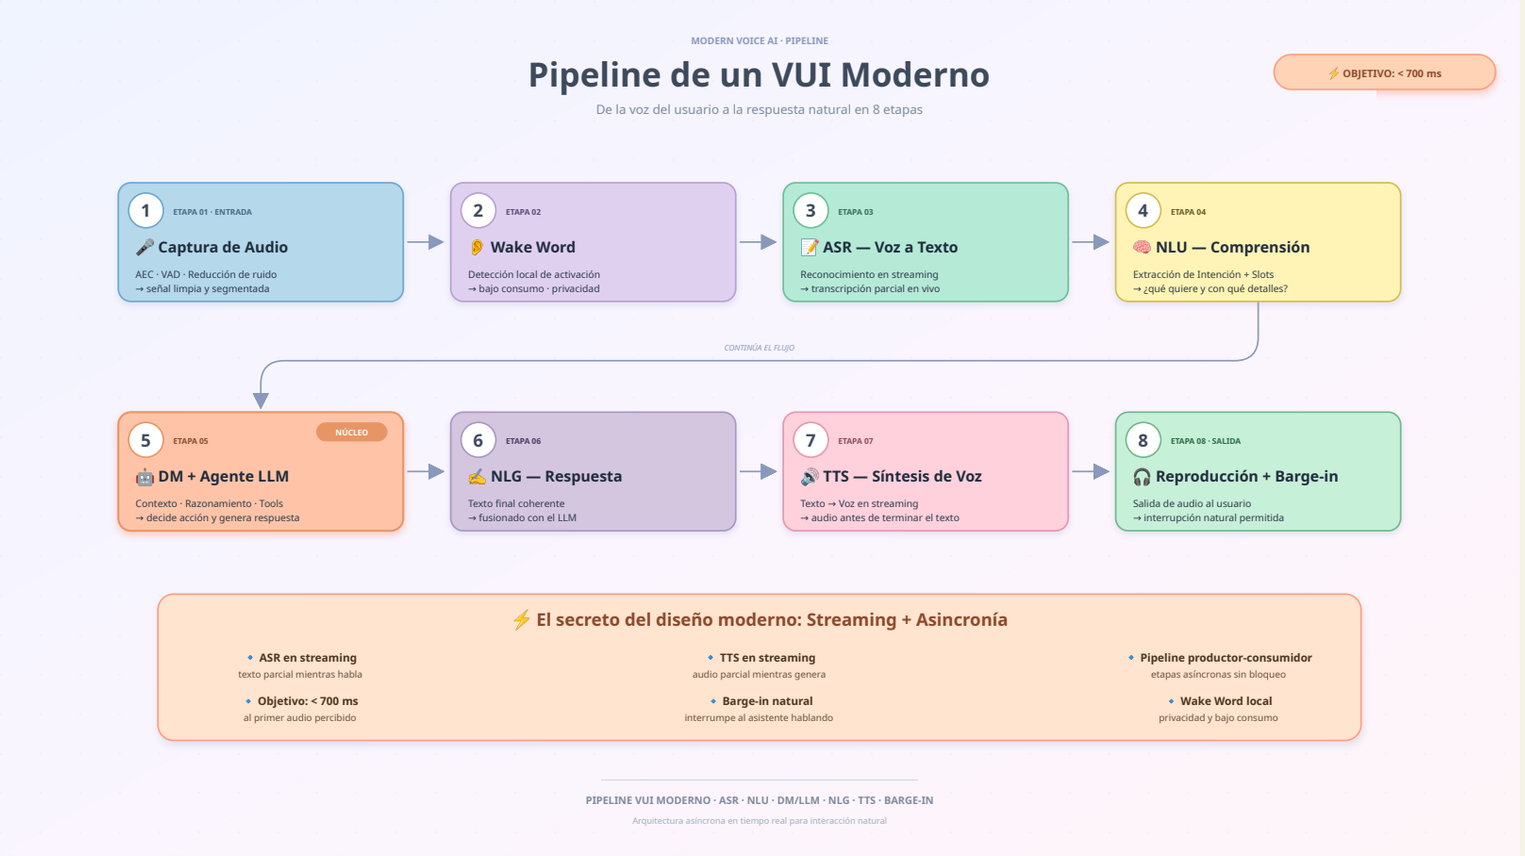
Pipeline Completo de VUI Moderno

8. Reproducción y "Barge-in"

Finalmente, el dispositivo reproduce el audio. Un VUI de calidad debe permitir el "barge-in" (interrupción): si el usuario empieza a hablar mientras el asistente responde, el sistema debe ser capaz de detener la reproducción de TTS inmediatamente y volver a activar el ASR para escuchar la nueva petición.

El Secreto de un VUI "Humano": la Latencia y el Streaming

La diferencia entre una experiencia frustrante y una conversación natural es el tiempo hasta el primer audio. Los pipelines modernos se diseñan como flujos asíncronos (productor-consumidor) para que ninguna etapa bloquee a la siguiente. El objetivo es que el tiempo desde que el usuario termina de hablar hasta que escucha la primera palabra de la respuesta sea inferior a 700 ms.



ASR Moderno: Datasets

Common Voice by Mozilla

Over 80 languages
Around 20,000+ hours of validated recordings
Crowdsourced from volunteers worldwide
Open source and freely available
Includes demographic metadata

VoxPopuli

15 European languages
~1800 hours of transcribed speech
Derived from European Parliament recordings
High-quality political speech data
Includes cross-lingual alignments

MLS (Multilingual LibriSpeech)

8 languages: English, German, Dutch, Spanish, French, Italian, Portuguese, Polish
~6000 hours total
Based on LibriVox audiobooks
Careful quality control and alignment

Babel Dataset

~25 low-resource languages
Approximately 80 hours per language
Conversational telephone speech
Created by IARPA
Includes languages like Zulu, Swahili, Bengali

M-AILABS Speech Dataset

9 languages including English, German, Spanish, French, Italian
Derived from audiobooks
~1000 hours total
Public domain content

MediaSpeech

8 languages
~80 hours per language
Broadcast news recordings
Professional speech quality

CoVoST

Mozilla's multilingual speech-to-text translation dataset
11 source languages to English
English to 15 target languages
Based on Common Voice recordings

NLU: De Intents a Comprensión Profunda

Enfoque Tradicional

Requiere definir intents por adelantado, mantenimiento costoso, poca flexibilidad con variaciones lingüísticas.

Ejemplo: 'Quiero una pizza grande de pepperoni'

→ Intent: OrderPizza
→ Entities: {size: 'grande', topping: 'pepperoni'}

Limitaciones:

→ Requiere definir intents por adelantado
→ Dificultad para manejar consultas complejas
→ Poca flexibilidad
→ Mantenimiento costoso (Añadir nuevos Intents)

Enfoque Moderno con LLMs

Function calling automático, maneja variaciones naturales sin re-entrenamiento, comprensión de contexto complejo.

Ejemplo: 'Dos pizzas familiares, una con todo excepto anchoas'

→ LLM procesa automáticamente múltiples parámetros y exclusiones y detecta informacion faltante

Ventajas:

→ Maneja Lenguaje natural sin restriccoiones
→ Entiende contexto de multiples turnos
→ Puede razonar sobre informacion ambigua
→ Se adapta sin reentrenamiento

IA Generativa: Modelos Principales 2026

GPT-Live

Ofrece modelos de voz en tiempo real (Realtime 2.0 API) y traducción

Claude Opus 4.7

Acepta dictado por voz como entrada, sin cap. de voz de salida nativas.

Gemini Audio

Nativamente multimodal, soporta entrada y salida de audio

Assembly AI

Soporta TTS - STT

Qwen 3.6 Max-Preview

Especializado en interacciones de voz. Streaming de voz en tiempo real

Capacidades Clave

- Comprensión contextual profunda
- Conversaciones multi-turn naturales
- Manejo inteligente de ambigüedad
- Razonamiento y sugerencias contextuales

Ventajas para VUI

- Adaptación de tono y personalidad
- Memoria conversacional persistente
- Function calling para acciones
- Recovery inteligente de errores

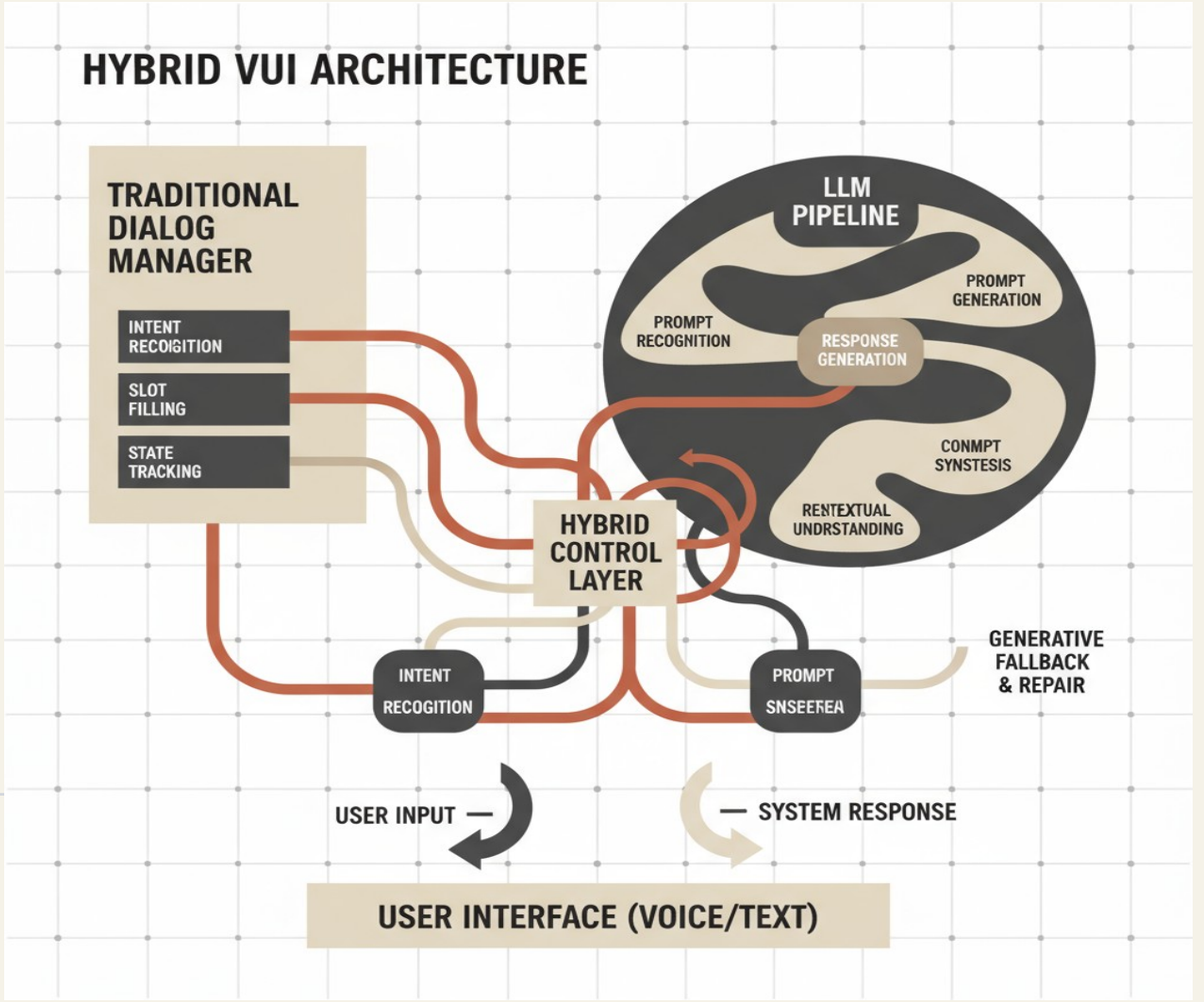
Arquitectura Híbrida

Problema: Limitaciones de LLMs puros

- $ Costo elevado a escala
- Latencia 500ms-2s
- No determinístico
- Alucinaciones

Solución: Sistema Híbrido

- T **Tradicional:** Flujos transaccionales simples, respuestas exactas
- L **LLM:** Consultas complejas, manejo de quejas, personalización



TTS de Nueva Generación

Evolución

- Concatenativo (2000s)
- Paramétrico (2010s)
- Neural (2015+) → Clonación (2023+)

Tecnologías Actuales

- **ElevenLabs:** Clonación con 1 min de audio, 29+ idiomas
- **Google WaveNet:** 220+ voces, control SSML
- **VALL-E:** Zero-shot voice cloning

Características Clave

Prosodia Natural

Entonación contextual, pausas naturales, énfasis apropiado

Expresividad

Emociones variables, estilos (noticiero, asistente), intensidad

Multilingüismo

Mismo voice ID en múltiples idiomas, code-switching

Personalización

Voces custom para marca, ajuste de velocidad y tono,

Conocimiento del contexto

incorporación del contexto para crear interacciones significativas.

Principio #1: Diseño de Personalidad

La VUI debe tener una personalidad consistente y apropiada al contexto, definida por tono, vocabulario, humor y nivel de empatía.

Banco (Formal)

Saludo: Buenos días, banca digital.

Confirmación: Confirmo transferencia de 500 soles.
Error: No puedo procesar esa transacción.

Pizza (Casual)

Saludo: ¡Hola! ¿Listo para algo delicioso?

Confirmación: ¡Genial! Tu pizza está en camino.

Error: ¡Ups! No entendí, ¿me repites?



Principio #2: Progressive Disclosure

❌ MAL: ABRUMAR CON OPCIONES

'Bienvenido. Puedes ordenar pizza, pasta, ensaladas, bebidas, postres, ver tu historial, modificar tu información, hablar con soporte, ver promociones, o consultar alérgenos. ¿Qué deseas hacer?'

✓ BIEN: REVELAR GRADUALMENTE

'¡Hola! ¿Quieres ordenar algo o prefieres ver las promociones?'

→ [Usuario responde] → Continúa basado en la elección

Estrategia de Implementación

1. Comenzar con 2-3 opciones
2. Revelar sub-opciones
3. Permitir interrupciones
4. Ofrecer escape

Principio #3: Confirmaciones Inteligentes

Bajo Riesgo

U: 'Un helado de chocolate'
VUI: 'Ok, un helado de chocolate'

Alto Riesgo

U: 'Cancela mi pedido'
VUI: '¿Confirmas cancelar pedido #1234?'

Alta Confianza

Confirmación implícita para acciones de bajo riesgo.

Baja Confianza

Confirmación explícita y repetición para acciones de alto riesgo.

Principio #4: Error Prevention > Error Handling

❌ MAL: INPUT ABIERTO

'¿Cuál es tu dirección?'

→ Respuestas variables, difícil validación

✓ BIEN: CONSTRAINT EL INPUT

'¿En qué distrito te encuentras?'

→ Lista limitada de opciones válidas

Estrategias de Prevención

1. Defaults Inteligentes

'Enviando a Jr. Las Flores 123 [tu última dirección]'

2. Validación en Tiempo Real

'Máximo 10 pizzas por pedido online'

3. Clarificación Proactiva

'¿Tamaño personal, mediana o familiar?'

En voz, corregir es más costoso que en GUI porque es secuencial. Los LLMs ayudan con clarificaciones naturales.

Principio #5: Memoria Conversacional

Memoria Inmediata

Contexto de la sesión actual (1-5 turnos)

U: 'Los mismos de la anterior'

VUI: Entiende el contexto inmediato

Memoria de Sesión

Toda la conversación actual

U: 'Cancela eso'
VUI: '¿Cancelo tu pizza mediana de pepperoni?'

Memoria Persistente

Entre sesiones (cumple co - GDPR - Reglamento General de Protección de Datos)

VUI: '¡Hola María! ¿Lo de siempre?'

U: 'Hoy quiero probar algo diferente'

Más memoria = más costo

GDPR: opción de borrar

Transparencia requerida

Principio #6: Multimodalidad Inteligente

Voz + Pantalla

Alexa Show, Google Hub

VUI: 'Estas son las 3 pizzas más populares'

[Muestra fotos en pantalla]

U: 'La del medio'

Voz → Mobile

Manos libres en auto

U: 'Ordena mi pizza favorita'

VUI: 'Listo. Te envié el recibo a tu app'

[Tracking en app]

App → Voz

Handoff por dificultad

App: '¿Necesitas ayuda? Puedes hablar con nuestro asistente'

[Switch a voz para resolver]

Usa voz para input rápido y manos libres. Usa visual para info densa y selección múltiple. GPT-4o y Gemini son nativamente multimodales.

Resumen: Principios de VUI Modernas

1. **Personalidad Consistente**
   Tono y vocabulario apropiado
2. **Progressive Disclosure**
   No abrumar con opciones
3. **Confirmaciones Inteligentes**
   Basadas en riesgo y confianza
4. **Error Prevention**
   Prevenir antes que corregir
5. **Memoria Conversacional**
   Contexto persistente con LLMs
6. **Multimodalidad**
   Voz + visual integradas

La IA generativa no reemplaza el diseño conversacional, sino que lo potencia con capacidades avanzadas de comprensión y generación .